# Přenos dat, počítačové sítě a protokoly Architektura přepínačů

Ing. Petr Matoušek, Ph.D., M.A.



Fakulta informačních technologií VUT v Brně

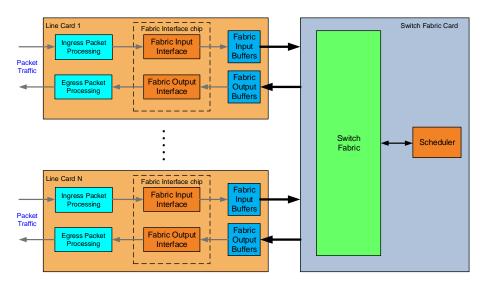
matousp@fit.vutbr.cz

### Obsah přednášky



- Přepínání paketů
- Základní architektury přepínačů
- Openie proceso a proceso proceso se proceso a proceso
  - Párování
  - Přidělování lístků
  - Algoritmus PIM
  - Algoritmus iSLIP
- Vícestupňové přepínání
  - Closův obvod
  - Benešův obvod
- Otázky a úkoly
- 6 Literatura



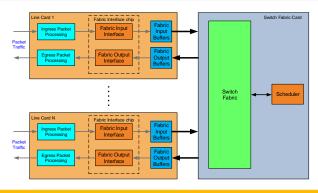




#### Základní části přepínače

- Vstupní rozhraní (fabric input interface)
  - Propojuje vstupní modul a přepínací logiku
  - Rozděluje příchozí pakety na buňky pevné délky pro přepínání
  - Odesílá data na přepínací logiku na pokyn plánovače
- Vstupní buffer (fabric input buffer)
  - Ukládá příchozí data, pokud je není možné poslat do přepínací logiky
- Přepínací logika (switch fabric)
  - Dynamicky propojuje síťové rozhraní a přenáší mezi nimi data.
  - Vytváří propojení pomocí přepínacích obvodů či sběrnic.
  - Implementována na základní desce
- Plánovač (scheduler)
  - Plánuje přepínání dat ze vstupu na výstup
- Výstupní rozhraní (fabric output interface)
- Výstupní buffer (fabric output buffer)

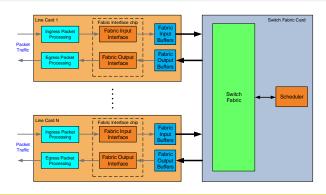




#### Požadavky na činnost přepínače

- Maximální přenos dat přepínací logikou
- Paralelní přenosy mezi různými síťovými rozhraními
- Spravedlivé přidělování přenosového pásma
- Zachování pořadí paketů



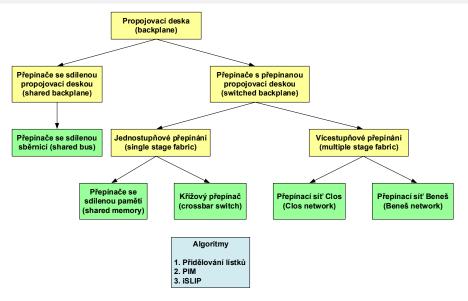


#### Metriky pro měření činnosti přepínače

- Propustnost: množství dat přenesných za jednotku času (bps či pps)
- Latence: doba přenosu paketu ze vstupního na výstupní rozhraní (s)
- Počet dostupných cest v přepínací logice, které propojují každou dvojici vstupních a výstupních portů (blokující vs. neblokující přepínání).

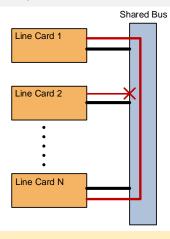
# Klasifikace přepínačů [1]





# Přepínače se sdílenou sběrnicí



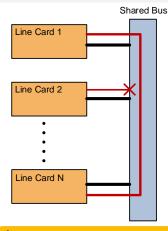


- Sdílené přenosové médiu
- Bus protocol ⇒ řízení přenosů
- Potřebná propustnost sběrnice: R × N
- Potřebná šířka sběrnice:  $w = \frac{R \times N}{r}$ 
  - R: šířka pásma na portu
  - N: počet portů
  - r: taktovací frekvence sběrnice
- Vhodné pro zařízení s propustností 1 Gb/s

- Nativní implementace přenosu broadcast a multicast
- Pouze jeden port může v daný okamžik komunikovat
- S počtem portů roste šířka sběrnice

# Přepínače se sdílenou sběrnicí





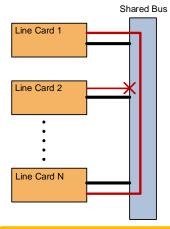
- Sdílené přenosové médiu
- Bus protocol ⇒ řízení přenosů
- Potřebná propustnost sběrnice: R × N
- Potřebná šířka sběrnice:  $w = \frac{R \times N}{r}$ 
  - R: šířka pásma na portu
  - N: počet portů
  - r: taktovací frekvence sběrnice
- Vhodné pro zařízení s propustností 1 Gb/s

#### Úkol:

 Přepínač má 16 portů o rychlosti 100 Mb/s. Jaká je potřebná propustnost sběrnice a jaká musí být šířka sběrnice, aby zvládl požadovaný přenos? Uvažujte taktovací frekvenci sběrnice 40 MHz.

# Přepínače se sdílenou sběrnicí





- Sdílené přenosové médiu
- ullet Potřebná propustnost sběrnice:  $R \times N$
- Potřebná šířka sběrnice:  $w = \frac{R \times N}{r}$ 
  - R: šířka pásma na portu
  - N: počet portů
  - r: taktovací frekvence sběrnice
- ⇒ Co se stane, když přidáme porty?
- ⇒ Co se stane, když se zvýší rychlost na portech?

#### Řešení:

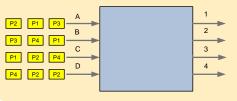
Přepínač má 16 portů o rychlosti 100 Mb/s, taktovací frekvence je sběrnice 40 MHz.

• Propustnost  $R \times N = 1.6$  Gb/s; šířka sběrnice  $w = \frac{R \times N}{r} = \frac{100.10^6 \times 16}{40.10^6} = 40$  bitů

# Přepínaná propojovací deska (switched backplane)

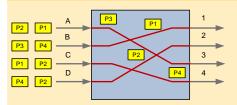


#### Vlastnosti



- Paralelní přenos paketů
- Buňky pevné délky
- Potřeba plánování: plánovač (scheduler)

#### Proces plánování přenosu

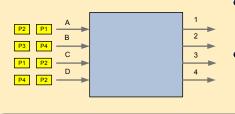


- Detekce buněk na vstupu
- Plánování přenosu
- Přenos buněk

# Přepínaná propojovací deska (switched backplane)



#### Příklady architektur s přepínanou propojovací deskou



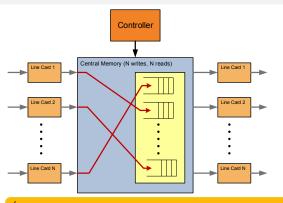
- Jednostupňové:
  - se sdílenou pamětí
  - křížový přepínač
- Vícestupňové:
  - Closova síť
  - Benešova síť
  - Torus

#### Plánovač (Scheduler)

- Činnost plánovače
  - Problém párování portů
  - Vnitřní blokování a virtuální fronty
- Algoritmy pro plánování
  - Přidělování lístků (take-a-ticket)
  - Algoritmus PIM (Parallel Iterative Matching)
  - Algoritmus iSLIP (Iterative round-robin matching with SLIP)

# Přepínač se sdílenou pamětí (shared memory)





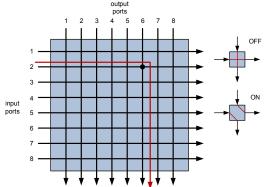
- Centrální sdílená paměť
- Fronty pro výstupní porty
  - Oblasti pevné velikosti
- Oblasti proměnné velikosti
- Rychlost přístupu do paměti
  - $BW = 2 \times N \times R [b/s]$
  - R: rychlost síťového rozhraní
  - N: počet síťových karet
- Doba přenosu dat o velikosti C
  - $t = \frac{C}{BW}[s]$

#### Úkol

- Jaká je potřebná doba zápisu do paměti u přepínače se sdílenou pamětí, který má 32 portů o rychlosti 1 Gb/s a velikost ukládané buňky je 40 bytů? Jak se tato doba změní pro rychlosti portů 10 Gb/s a 40 Gb/s?
- $t_1 = \frac{c}{2 \times R \times N} = \frac{40 \times 8}{2 \times 32 \times 10^9} = 5.10^{-9} \text{ s} = 5 \text{ ns}; \ t_{10} = 0, 5 \text{ ns}; \ t_{40} = 0, 125 \text{ ns}.$
- Přístupová doba pamětí SDRAM je 5 − 10 ns, u pamětí DRAM cca 50 ns.

# Křížový přepínač (crossbar)





- N<sup>2</sup> propojení (crosspoints)
  - Dvoustavové chování (on/off)
  - Implementace např. tranzistory
- Interně neblokující architektura
  - Paralelní přenosy
- Nativní podpora multicastu
- Jednoduchá implementace
- Centrální plánovač
  - Plánuje konfigurace přepínače
  - Nastavení pomocí řídící linky

#### Další vlastnosti křížového přepínače

- Náročná rozšiřitelnost: kvadratická složitost  $\mathcal{O}(N^2)$
- Možnost kolizí: více vstupů požaduje jeden výstup
- Obtížná garance kvality služeb při souběžných požadavcích
- Chybí redundance: pouze jedna cesta mezi vstupem a výstupem



#### Algoritmický problém párování

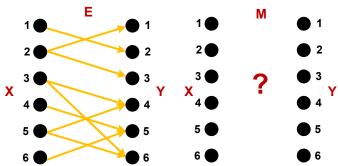
- Bipartitní graf  $G = (X \cup Y, E)$
- Uzly: množina vstupních portů X a množina výstupních portů Y
- Hrany: množina propojení E (požadavky na přenos dat)

vstupní porty	výstupní porty
1	<b>1</b>
2	<b>2</b>
3 🜑	● 3
<b>X</b> 4 ●	• 4
5	<b>5</b>
6	<b>6</b>



#### Algoritmický problém párování

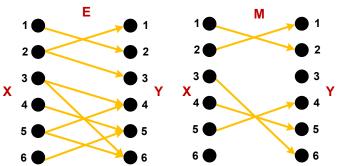
- Bipartitní graf  $G = (X \cup Y, E)$
- Uzly: množina vstupních portů X a množina výstupních portů Y
- Hrany: množina propojení E (požadavky na přenos dat)
- Párování vstupních portů X na výstupní porty Y
- ullet Hledáne takové párování  $M\subseteq E$ , kde žádné dvě hrany z M nemají společný vrchol





#### Algoritmický problém párování

- Bipartitní graf  $G = (X \cup Y, E)$
- Uzly: množina vstupních portů X a množina výstupních portů Y
- Hrany: množina propojení E (požadavky na přenos dat)
- Párování vstupních portů X na výstupní porty Y
- ullet Hledáne takové párování  $M\subseteq E$ , kde žádné dvě hrany z M nemají společný vrchol



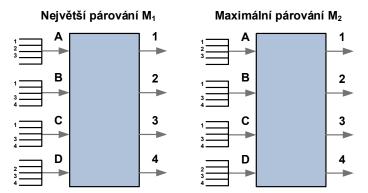


#### Největší vs. maximální párování

- Největší párování (maximum matching): párování, které má největší počet hran
- Maximální párování (maximal matching): párování, kdy nelze přidat další hranu

Požadavek na přenos:

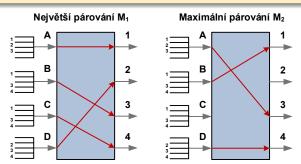
$$\{(A,1),(A,2),(A,3),(B,1),(B,3),(B,4),(C,1),(C,3),(C,4),(D,2),(D,3),(D,4)\}$$





#### Největší vs. maximální párování

- Největší párování (maximum matching): obsahuje největší možný počet hran
  - Globální maximum s největší propustností
  - Složitost vyhledání  $\mathcal{O}(N^{\frac{5}{2}})$  či  $\mathcal{O}(N+E)$
  - Nebezpečí vyhladovění
- Maximální párování (maximal matching)
  - Nelze přidat další hranu, aniž bychom zvýšili stupeň některého z uzlů na dva.
  - Lokální maximum



### Plánovací algoritmus přidělování lístků

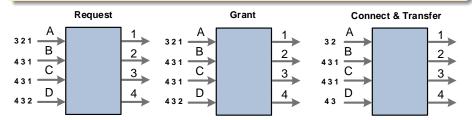


#### Princip algoritmu

- Výstupní port Q obsluhuje frontu požadavků na propojení.
- ullet Požadavek na vstupu P dostane od Q číslo  $T_{QX}$  na obsloužení portu Q s pořadím X
- ullet Výstupní porty jsou přiděleny žádostem s nižším  $T_{QX}$

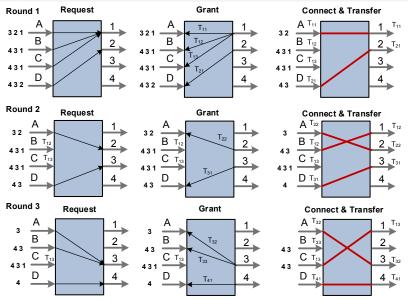
#### Fáze algoritmu

- Žádost o lístek (Request)
- Přidělení lístku (Grant)
- 3 Propojení vstupů a výstupů, přenos (Connect & Transfer)



# Plánovací algoritmus přidělování lístků: Příklad





### Plánovací algoritmus přidělování lístků: Příklad



Přehled přenesených paketů

	Time Slot 1	Time Slot 2	Time Slot 3	Time Slot 4	Time Slot 5	Time Slot 6
Input A	1	2	3			
Input B		1		3	4	
Input C			1		3	4
Input D	2	3	4			

#### Zhodnocení algoritmu

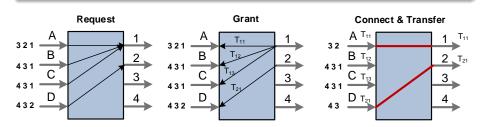
- Umožňuje asynchronní zpracování
- Přenos rámců proměnné délky
- Blokování na začátku fronty (HOL, Head of Line Blocking)
- Nezávislé přidělování lístků: problém u multicastu

# Blokování na začátku fronty (HOL, Head of line)



#### Příčiny blokování

- Pakety na vstupních portech čekají ve frontě FIFO
- První buňka v pořadí blokuje další požadavky
- Blokované buňky čekají, i když je cílový port dostupný



#### Co s tím?

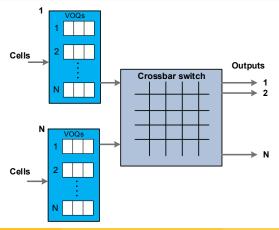
• Rozdělení vstupní fronty na více virutálních front podle cílových portů

# Blokování na začátku fronty (HOL, Head of line)



#### Virtuální výstupní fronty VOQ (Virtual Output Queues)

- Pro každý výstupní port vytvořena na daném vstupu jedna fronta
- Celkově potřebujeme N<sup>2</sup> front

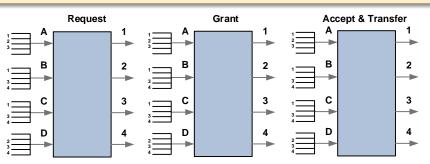


# Algoritmus PIM (Parallel Iterative Matching)



#### Princip algoritmu

- Pracuje podobně jako algoritmus přidělování lístků, využívá virtuální fronty
- Hledá maximální párování pomocí *náhodné volby* požadavku ze vstupního portu
- Soutěžení o porty:
  - výstupní porty: více žádostí na jeden výstup
  - vstupní porty: více povolení pro data na jednom portu

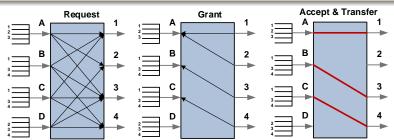


# Algoritmus PIM (Parallel Iterative Matching)



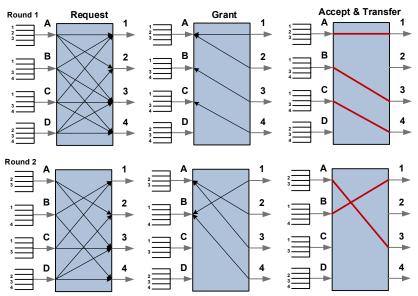
#### Fáze algoritmu

- 1 Žádost o port (Request)
  - Vstupní port P posílá žádosti ze všech front na všechny žádané porty.
- 2 Udělení portu (Grant)
  - Výstupní port Q přidělí právo přenosu.
  - V případě více žádostí o port Q, vybere náhodně jednu žádost.
- 3 Přijetí a přenos (Accept & Transfer)
  - Vstupní port P zpracuje udělená povolení k přenosu.
  - V případě udělení více povolení, *náhodně* vybere jedno. Dojde k přenosu dat.



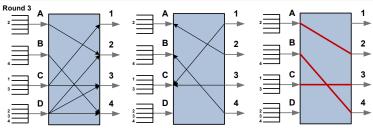
# Algoritmus PIM: Příklad





# Algoritmus PIM: Příklad





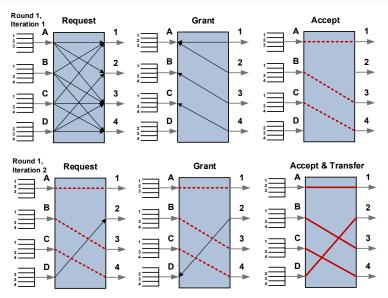
• Přehled přenesených paketů

	Time Slot 1	Time Slot 2	Time Slot 3	Time Slot 4	Time Slot 5	Time Slot 6
Input A	1	3	2			
Input B	3	1	4			
Input C	4		3	1		
Input D				2	3	4

- 6 časových slotů, 4 porty ⇒ 24 možností přenosu
- Použito 12 přenosů z 24 ⇒ propustnost 50%

# Algoritmus PIM: Optimalizace pomocí více iterací





# Algoritmus PIM: Optimalizace pomocí více iterací



#### Přehled přenesených paketů

	Time Slot 1	Time Slot 2	Time Slot 3	Time Slot 4
Input A	1	3	2	
Input B	3	1	4	
Input C	4		3	1
Input D	2	4		3

- 4 časové sloty, 4 porty
  - ⇒ 16 možností přenosu
- Použito 12 přenosů z 16
  - $\Rightarrow$  propustnost 75%
- Problém generování náhodných čísel

#### Zhodnocení algoritmu PIM

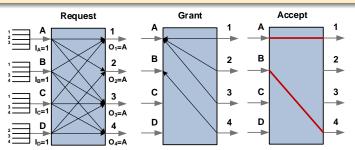
- Úspěšnost nalezení největšího párování
  - Nejhorší případ: N iterací (všechny vstupy na jeden výstup)
  - Nejlepší případ: 1 iterace (každý vstup na jiný výstup)
  - Průměr:  $\mathcal{O}(\log_2 N)$
- Počet iterací vs. doba párování
  - Obecně variabilní počet iterací, v praxi pevně dané
  - Experimentální výsledky pro velké N: jedna iterace: 63%, dvě iterace: 75%

### Algoritmus iSLIP



#### Princip algoritmu

- Iterativní algoritmus pro hledání maximálního párování
- Při soupeření o port používá algoritmus rotujících ukazatelů:
  - Ii: ukazatel na vstupním portu i (přijetí žádosti)
  - $O_i$ : ukazatel na výstupním portu i (udělení povolení k přenosu)
- Přidělení probíhá iterativně. Po každé iteraci se ukazatele inkrementují.
  - $I_i' = (I_i + 1) \mod N$
  - $O'_i = (O_i + 1) \mod N$
  - Ukazatele se inkrementují, až když je žádost o port potvrzena.

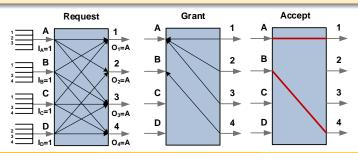


### Algoritmus iSLIP



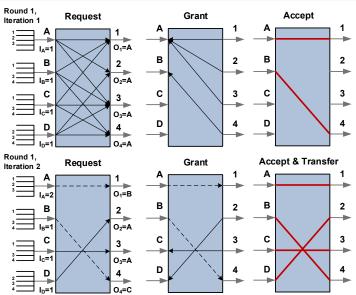
#### Fáze algoritmu

- 1 Žádost o port (Request)
  - Každý port pošle žádost na každý výstupní port
- 2 Udělení portu (Grant)
  - Výstupní port Y vybere žádost, která má číslo portu větší nebo rovno ukazateli  $O_i$ ; v případě více žádostí se vybere žádost s nejmenší hodnotou
- Přijetí volby (Accept)
  - Vstupní port X vybere povolení od portu, které je větší nebo rovno ukazateli  $I_i$ ; v případě více povolení se vybere povolení s nejmenší hodnotou



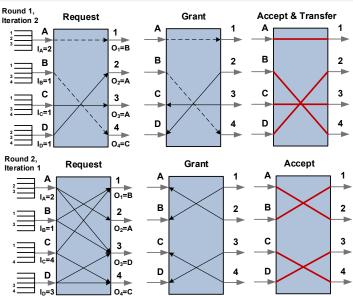
# Algoritmus iSLIP: Příklad





# Algoritmus iSLIP: Příklad





### Algoritmus iSLIP: Příklad



Přehled přenesených paketů

	Time Slot 1	Time Slot 2	Time Slot 3	Time Slot 4
Input A	1	2	3	
Input B	4	1		3
Input C	3	4	1	
Input D	2	3	4	

#### Zhodnocení algoritmu iSLIP

- 4 časové sloty, 4 porty ⇒ 16 možností přenosu
- Použito 12 přenosů z 16 ⇒ propustnost 75%
- Deterministická obsluha (vs. náhodná u PIM)

# Vícestupňové přepínání



#### Vlastnosti jednostupňového přepínání

- Využívá se převážně křížového přepínače (crossbar)
- Problémy s kvadratickým nárůstem portů
- Vnitřní blokování, blokování HOL
- Součástí přepínání je hledání maximálního párování

Je možné zvětšit počet portů, aniž by se dramaticky rozšířilo přepínací pole?

Ano ⇒ s použitím vícestupňového přepínání.

#### Vlastnosti vícestupňového přepínání

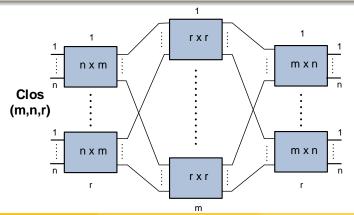
- Sítě typu Clos a Beneš
  - vstup → vnitřní přepínací obvody → výstup
- Vícestupňového obvody nemají vnitřního blokování.
- Součástí přepínání je vytvoření bezkonfliktního propojení.

# Přepínací síť Clos(m,n,r)



#### Třístupňová přepínací síť Clos(m,n,r)

- ullet r vstupních křížových přepínačů s n vstupy  $\Rightarrow$  přepínač má  $N=n\times r$  portů
- m vnitřních křížových přepínačů s r vstupy ⇒ propojují každý V/V blok
- Mezi každým vstupním a výstupním portem existuje *m* různých cest.

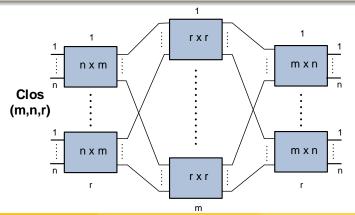


### Přepínací síť Clos(m,n,r)



#### Closův teorém (neblokující síť)

- ullet Pokud m  $\geq 2n-1$ , pak lze přidat nové propojení vstupu a výstupu bez přeskládání.
- Tehdy je přepínač pro jakoukoliv konfiguraci vstupů a výstupů neblokující.
- Nevýhoda ⇒ síť vyžaduje velký počet vnitřních bloků.

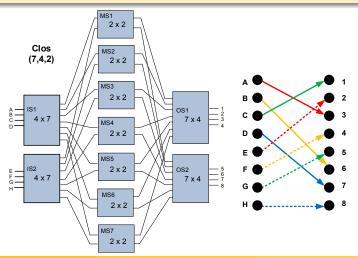


## Přepínací síť Clos(m,n,r)



#### Příklad neblokující sítě Clos(7,4,2): osmiportový přepínač

• Platí Closův teorém, tj.  $m \ge 2n - 1$ 



# Přepínací síť Clos(m,n,r): Vlastnosti



#### Vlastnosti sítě Clos(m,n,r)

- Přepínač s N vstupními porty potřebuje síť  $(m, n, \lceil N/n \rceil)$ .
- Pokud  $n = \sqrt{N/2}$ , pak minimální počet propojení je  $5.76 \times N \times \sqrt{N}$ .
- Počet propojení je stále lepší než křížový přepínač, tj. než  $N^2$ .

#### Neblokující chování

- Pro neblokující chování musí platit Closův teorém, tj.  $m \ge 2n 1$ .
- Například přepínač o 256 portech vyžaduje síť  $(31,16,16) \rightarrow drahé$ .

#### Modifikované řešení: síť Clos(m,n,r), kde $m \ge n$

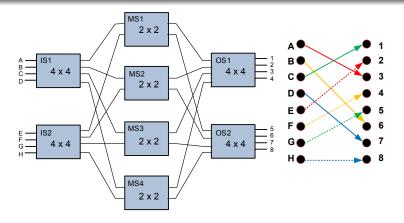
- ullet Redukován počet prostředních přepínačů o levnější.
- Síť není neblokující pro libovolnou konfiguraci vstupů. a výstupů.
- Vlastnost modifikované sítě: síť je neblokující po přeskládání.
  - Výpočet přeskládání musí být rychlejší než přenos dat.
  - Používají se algoritmy barvení hran v bipartitním multigrafu.



# Modifikovaná přepínací síť Clos(m,n,r)

#### Příklad sítě Clos(4,4,2): osmiportový přepínač

- Síť Clos(4,4,2) je neblokující po přeskládání, protože  $m \ge n$ .
- Výpočetní složitost přeskládání je  $\mathcal{O}(N.log\ D)$ , kde D je počet barev.

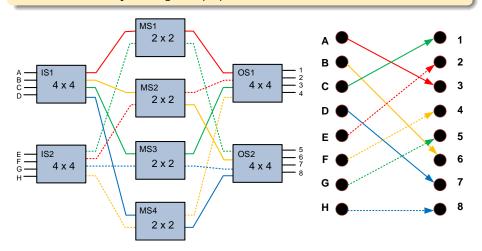


# Modifikovaná přepínací síť Clos(m,n,r)



#### Příklad sítě Clos(4,4,2): osmiportový přepínač

• Příklad neblokující konfigurace po přeskládání.

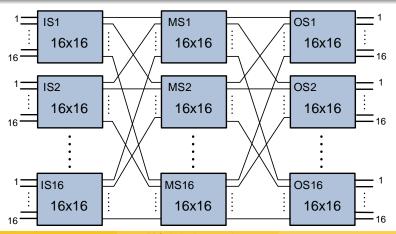


### Modifikovaná přepínací síť Clos(m,n,r)



#### Použití sítě Clos(16,16,16) v přepínači Juniper, T-series

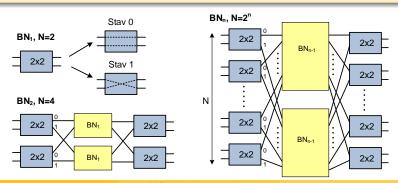
- Třístupňový přepínací modul o velikosti 256 portů (celkem 48 přepínacích bloků)
- Využito u přepínačů typu Juniper či Cisco ASR 9000





#### Rekurzivní přepínací síť Beneš BNn

- Základem je modifikovaná síť Clos(2,2,1) s přeskládáním
- Rekurzivní konstrukce sítě BN<sub>n</sub>
  - Počet vstupů (portů):  $N = 2^n$
  - Blok N/2-vstupních a N/2-výstupních přepínačů  $2 \times 2$
  - Prostřední část rekurzivních bloků BN<sub>(n-1)</sub>
  - Počet bloků (stupňů):  $2.\log_2(N) 1$

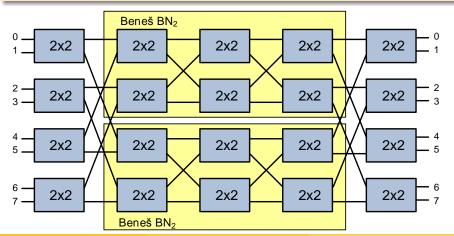


# Přepínací síť Beneš $BN_n$



#### Příklad: přepínací síť Beneš BN<sub>3</sub>

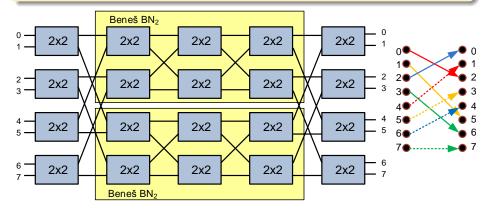
- N = 8 vstupů, 5 stupňů
- Použito např. u směrovače Cisco CSR-1.





#### Propojování sítě

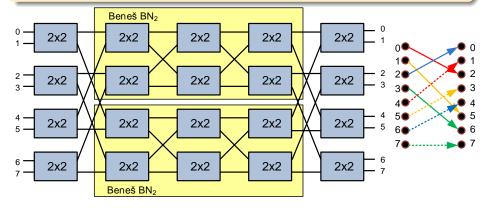
- Hledáme propojení počet propojení je N!
- Časová složitost algoritmů je  $\mathcal{O}(\sqrt{N})$  kroků.
- Používá se jednoduchý algoritmus využívající hierarchii sítě.





#### Algoritmus hledání propojení

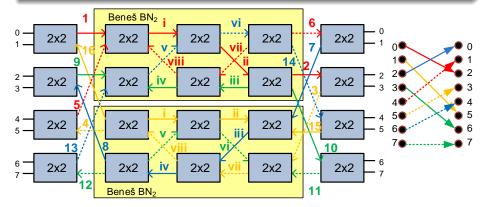
- Horní podsíť BN; slouží pro dopředné směrování, spodní podsíť BN; pro zpětné.
- Postupuje se od vstupů k výstupům a zpět, vždy pro sousední porty.
- Nejprve se propojí vstupní a výstupní bloky, poté rekurzivně síť  $BN_{i-1}$ .





#### Algoritmus hledání propojení

- Horní podsíť BN; slouží pro dopředné směrování, spodní podsíť BN; pro zpětné.
- Postupuje se od vstupů k výstupům a zpět, vždy pro sousední porty.
- Nejprve se propojí vstupní a výstupní bloky, poté rekurzivně síť  $BN_{i-1}$ .



# Otázky a úkoly k opakování l



- Popište základní části přepínače a jejich funkci.
- Popište vlastnosti a chování přepínače se sdílenou pamětí.
- Jaké jsou výhody a nevýhody křížového přepínače?
- Co je to blokování HOL a jak ho lze eliminovat?
- Popište princip a použití algoritmu PIM.
- Popište princip a použití algoritmu iSLIP.
- Porovnejte algoritmy přidělování lístků, PIM a iSLIP z hlediska efektivity, implementace a spravedlivosti.
- Uvažujte čtyřportový křížový přepínač se vstupy A až D a výstupy 1 až 4. Na vstupu přepínače je fronta paketů s těmito cílovými porty: A → (1,3,3), B → (2,3,4), C → (3,2,1), D → (4,3,1). Zapište, jak budou vypadat přenosy v časových slotech 1-6 při použití planování za použití algoritmu (i) přidělování lístků, (ii) PIM, (iii) iSLIP.

# Otázky a úkoly k opakování II



- Popište princip a chování přepínací sítě Clos.
- Uvažujte přepínač o velikosti 128 vstupních portů. Kolik vnitřních propojení by vyžadoval při implementaci pomocí (i) křížového přepínače, (ii) neblokující sítě Clos, (iii) neblokující sítě Clos po přeskládání?
- Navrhněte archikturu 16-portového přepínače pomocí přepínací sítě Clos tak, aby bylo přepínání (i) neblokující, (ii) neblokující s přeskládání.
- Zakreslete schéma přepínací sítě Clos (2,3,4).
- Popište architekturu a vlastnosti přepínací sítě Beneš.
- Zakreslete nastavení sítě  $BN_3$  pro následující konfiguraci vstupů a výstupů:  $\{(0,2),(1,6),(2,5),(3,0),(4,7),(5,1),(6,4),(7,3)\}$
- Zakreslete nastavení sítě  $BN_4$  pro následující konfiguraci vstupů a výstupů:  $\{(0,0),(1,4),(2,8),(3,12),(4,1),(5,5),(6,9),(7,7),(8,2),(9,6),(10,10),(11,14),(12,3),(13,7),(14,11),(15,15)\}$

### Použitá literatura



- D. Medhi and K. Ramasamy. Network Routing. Algorithms, Protocols, and Architectures. Elsevier, Inc., 2007.
- [2] George Varghese. Network Algorithmics. Elsevier, Inc., 2005.
- [3] Nick McKeown. The iSLIP Scheduling Algorithm for Input-queued Switches. IEEE/ACM Trans. Netw., 7(2):188–201, April 1999.
- [4] Thomas E. Anderson, Susan S. Owicki, James B. Saxe, and Charles P. Thacker. High speed switch scheduling for local area networks. In Proceedings of the Fifth International Conference on Architectural Support for Programming Languages and Operating Systems, ASPLOS V, pages 98–110, New York, NY, USA, 1992. ACM.
- William J. Dally.
   Scalable Switching Fabrics for Internet Routers.
   In Standford University and Avici Systems, 1999.
- [6] Charles Clos.A Study of Nonblocking Switching Networks.Bell System Technical Journal, 32:406–424, 1952.
- [7] Jiří Demel. Grafy a jejich aplikace. Academia. 2002.